

UNIVERSIDAD COMPLUTENSE DE MADRID

FACULTAD DE COMERCIO Y TURISMO

MÁSTER PERMANENTE EN DATA SCIENCE, BIG DATA Y BUSINESS ANALYTICS

TÍTULO DEL PROYECTO

PARCHAR Intelligence

*Diseño de un Sistema Inteligente Basado en Procesamiento del Lenguaje Natural y
Business Analytics para el Análisis de la Experiencia Turística en Destinos Emergentes
de Colombia*

AUTOR: Leidy Johanna Moreno Posada

FECHA DE PRESENTACIÓN: Septiembre de 2026

MADRID, ESPAÑA

ÍNDICE GENERAL

- 1. Introducción y justificación**
- 2. Objetivos e hipótesis**
- 3. Alcance**
- 4. Metodología**
- 5. Recursos y herramientas tecnológicas**
- 6. Resultados y discusión**
- 7. PARCHAR Intelligence: aplicación y Business Intelligence**
- 8. Conclusiones y líneas futuras**
- 9. Bibliografía**
- 10. Anexos**

RESUMEN

El crecimiento de las plataformas digitales ha convertido las reseñas turísticas en una fuente relevante de información sobre la experiencia de los visitantes. Sin embargo, su carácter textual, disperso y no estructurado dificulta su aprovechamiento sistemático para apoyar la toma de decisiones en destinos y organizaciones del sector. En este contexto, el presente Trabajo Fin de Máster desarrolla **PARCHAR Intelligence**, una propuesta de inteligencia turística que integra técnicas de **Data Engineering**, **Procesamiento del Lenguaje Natural (PLN)**, **Machine Learning** y **Business Intelligence** para transformar reseñas de viajeros en información analítica útil. Su nombre toma como referencia el verbo coloquial colombiano “parchar”, asociado a compartir, encontrarse y disfrutar de un lugar o experiencia, vinculando así la identidad local de la propuesta con la experiencia turística que busca analizar.

El estudio se desarrolló a partir de un dataset analítico final de **861 reseñas correspondientes a 25 puntos de interés (POI) de cinco destinos turísticos colombianos**, enriquecido con variables estructurales y contextuales procedentes de distintas fuentes externas. Se compararon siete especificaciones predictivas (M0–M6), desde un baseline de clase mayoritaria hasta combinaciones de información textual, estructural y contextual. La selección se realizó exclusivamente sobre el conjunto de entrenamiento mediante validación cruzada estratificada, manteniendo un conjunto de prueba independiente para la evaluación final.

La especificación seleccionada fue **M4 — Texto + Estructura**, basada en representación **TF-IDF** y un clasificador **LinearSVC**, al obtener el mejor desempeño global durante la selección pre-test. En el conjunto de prueba alcanzó una **Balanced Accuracy de 0,805**, un **Macro-F1 de 0,787** y un **F1 de 0,643 para la clase No positiva**. Los análisis complementarios mostraron, además, que el comportamiento relativo de las especificaciones puede variar ante escenarios de ampliación de datos y cambios en las condiciones de evaluación, evidenciando la importancia de considerar la robustez y la capacidad de generalización junto con el rendimiento predictivo.

Como resultado, **PARCHAR Intelligence** articula un pipeline reproducible que conecta la preparación e integración de datos, el modelado predictivo y la generación de información orientada a negocio. El proyecto constituye una base analítica para apoyar la comprensión de la experiencia turística y explorar futuras aplicaciones de inteligencia de destinos, manteniendo explícitas las limitaciones de los datos y del alcance de generalización del modelo.

1. Introducción y Justificación del Problema

Las plataformas digitales concentran una cantidad creciente de reseñas generadas por viajeros sobre alojamientos, atractivos, restaurantes y otros servicios turísticos. Estas opiniones contienen información directa sobre la experiencia del visitante, pero su carácter textual y disperso dificulta convertirlas de manera sistemática en información útil para la gestión de destinos y prestadores turísticos.

Esta dificultad resulta especialmente relevante en destinos colombianos con potencial de crecimiento, donde la información disponible suele encontrarse distribuida entre múltiples fuentes y no siempre permite identificar con rapidez qué aspectos de la experiencia son valorados positivamente, dónde aparecen señales de insatisfacción o qué patrones pueden resultar relevantes para la toma de decisiones.

Frente a esta necesidad, el presente Trabajo Fin de Máster desarrolla **PARCHAR Intelligence**, una propuesta de inteligencia turística que combina **Data Engineering, Procesamiento del Lenguaje Natural, Machine Learning y Business Intelligence** para transformar reseñas de viajeros en información estructurada, interpretable y potencialmente accionable.

1.1 Planteamiento del Problema

La información generada por los viajeros puede aportar una perspectiva complementaria a los indicadores tradicionales del sector turístico. Sin embargo, analizar manualmente grandes volúmenes de reseñas limita su aprovechamiento y dificulta comparar experiencias entre destinos, puntos de interés y tipos de servicio.

El problema abordado en este TFM consiste, por tanto, en determinar si las reseñas turísticas pueden transformarse mediante técnicas analíticas en una señal útil para clasificar experiencias en dos categorías: Positivas y No positivas. Esta última agrupa las valoraciones que no pertenecen a la clase positiva. El análisis busca además identificar patrones asociados con ambas categorías y complementar la señal textual con variables estructurales y contextuales.

¿Cómo convertir la voz digital del viajero en información analítica que pueda apoyar decisiones de gestión turística?

1.2 Justificación

PARCHAR Intelligence busca responder a esta pregunta mediante un enfoque reproducible que conecta tres niveles de valor.

En primer lugar, desde la perspectiva de **Data Science**, permite evaluar cuánto aporta realmente la información textual y si la incorporación de variables estructurales y contextuales mejora la capacidad predictiva.

En segundo lugar, desde la perspectiva de **Business Intelligence**, transforma los resultados técnicos en indicadores y visualizaciones orientados a perfiles que no necesariamente poseen conocimientos avanzados de Machine Learning.

Finalmente, desde una perspectiva aplicada, el proyecto desarrolla una base tecnológica extensible que permite explorar mecanismos de inferencia sobre nuevas reseñas y futuras soluciones de inteligencia turística, manteniendo diferenciados los resultados experimentales oficiales de los desarrollos complementarios.

El valor de PARCHAR no reside únicamente en predecir una clase, sino en **organizar la experiencia expresada por los visitantes y convertirla en información que pueda ser interpretada por prestadores, gestores y otros actores del sector turístico.**

2. OBJETIVOS E HIPÓTESIS DEL PROYECTO

2.1. Objetivo General

Diseñar y validar un modelo analítico reproducible basado en **Procesamiento del Lenguaje Natural, Machine Learning y Business Intelligence** para transformar reseñas turísticas reales en información útil para la toma de decisiones, utilizando como caso de estudio destinos colombianos y materializando sus resultados en PARCHAR Intelligence.

2.2. Objetivos Específicos

- **2.2.1.** Construir y preparar un dataset analítico propio a partir de reseñas turísticas reales y fuentes contextuales externas, garantizando su calidad y trazabilidad.
- **2.2.2.** Desarrollar un pipeline reproducible para la limpieza, transformación y representación de información textual, estructural y contextual.
- **2.2.3.** Comparar diferentes especificaciones predictivas para determinar el aporte del texto, la estructura y el contexto en la clasificación de reseñas como **Positivas y No positivas**.
- **2.2.4.** Evaluar el modelo seleccionado mediante métricas adecuadas al desbalance de clases, manteniendo la independencia entre TRAIN y TEST.
- **2.2.5.** Analizar la robustez, generalización e interpretabilidad del modelo, identificando sus principales fortalezas y limitaciones.
- **2.2.6.** Traducir los resultados analíticos a una perspectiva de negocio mediante Business Intelligence y el desarrollo de PARCHAR Intelligence como solución de apoyo a la gestión turística.

2.3. Hipótesis de Investigación

El diseño experimental se articula en torno a tres hipótesis:

- **Primera Hipótesis – Valor predictivo del texto:**

*Las reseñas turísticas contienen información suficiente para clasificar automáticamente experiencias **Positivas y No positivas**, superando un baseline sin capacidad discriminativa real.*

- **Segunda Hipótesis — Valor incremental de otras fuentes de información:**

La incorporación de variables estructurales y contextuales puede aportar capacidad predictiva adicional respecto al uso exclusivo del texto.

- **Tercera Hipótesis — Robustez y generalización:**

El comportamiento del modelo puede mantenerse bajo escenarios alternativos de evaluación y ampliación de datos, aunque su capacidad de generalización puede variar al aplicarse a territorios no observados durante el entrenamiento.

3. ALCANCE DEL PROYECTO

El estudio analiza reseñas turísticas correspondientes a **25 puntos de interés (POI)** distribuidos en cinco clústeres de destinos colombianos con características turísticas y territoriales diferenciadas:

1. **Amazonía:** Leticia.
2. **Pacífico colombiano:** Nuquí y Bahía Solano.
3. **Caribe Continental:** Palomino.
4. **Caribe Insular:** San Andrés y Providencia.
5. **Región Andina:** Barichara.

El dataset analítico final comprende **861 reseñas reales**, enriquecidas con información estructural de los POI y variables contextuales procedentes de fuentes externas. Sobre esta base se desarrolla un proceso reproducible de preparación, modelado y validación orientado a clasificar las experiencias turísticas como **Positivas y No positivas** y evaluar el valor incremental de los diferentes bloques de información.

El alcance incluye el análisis exploratorio, la comparación de especificaciones predictivas, la evaluación sobre un conjunto TEST independiente y los análisis de robustez, generalización e interpretabilidad. Los resultados se trasladan posteriormente a una capa de **Business Intelligence** y a una prueba de concepto de inferencia integrada en **PARCHAR Intelligence**.



Figura 1. Localización geográfica de los destinos incluidos en el estudio. Fuente: elaboración propia.

El proyecto no contempla el desarrollo ni despliegue de una aplicación comercial completa. PARCHAR Intelligence se plantea como una prueba de concepto y una arquitectura extensible, cuyos resultados quedan limitados al dominio, fuentes y territorios analizados en este TFM.

4. METODOLOGÍA

El estudio se desarrolló mediante un pipeline reproducible que integra **adquisición y preparación de datos, Procesamiento del Lenguaje Natural (PLN), modelado supervisado, validación e interpretabilidad**. El diseño experimental se orientó a determinar el valor predictivo del texto y el aporte incremental de variables estructurales y contextuales, manteniendo controles de calidad y prevención de *data leakage* durante todo el proceso.

4.1. Adquisición, integración y preparación de los datos

El dataset analítico se construyó a partir de reseñas turísticas reales obtenidas mediante **Outscrapers** para 25 puntos de interés de los destinos seleccionados. Estas observaciones se complementaron con variables estructurales asociadas al destino y al POI, así como con indicadores contextuales procedentes de fuentes externas.

El proceso de preparación incluyó controles de calidad, normalización de campos, tratamiento de valores faltantes y transformación de las variables según su naturaleza. Para el componente textual se aplicaron procedimientos de limpieza y normalización y una representación **TF-IDF**, adecuada para convertir las reseñas en una matriz numérica dispersa utilizable por los modelos supervisados.

La variable objetivo se definió como una clasificación binaria de la experiencia turística: **Positiva** y **No positiva**. El dataset final quedó conformado por 861 reseñas y 73 variables, con una distribución de 733 observaciones positivas (85,13 %) y 128 no positivas (14,87 %). Debido a este desbalance, la evaluación posterior priorizó métricas sensibles al desempeño de ambas clases.



Positiva	733 (85,13 %)
No Positiva	128 (14,87 %)

4.2. Diseño Experimental y modelado

Antes del modelado, el conjunto de datos se dividió de forma estratificada en **TRAIN (688 observaciones; 80 %)** y **TEST (173; 20 %)**. El conjunto TEST permaneció aislado durante el desarrollo y la selección del modelo y se utilizó únicamente para la evaluación final.

Sobre TRAIN se aplicó validación cruzada estratificada de cinco particiones, comparando siete especificaciones diseñadas para medir de forma incremental el aporte de las distintas fuentes de información:

Modelo	Información utilizada	Pregunta que responde
M0	Baseline	¿Qué ocurre sin capacidad predictiva real?
M1	Texto	¿Cuánto explica la reseña por sí sola?
M2	Estructura	¿Qué aporta el POI/destino?
M3	Contexto	¿Qué aporta el entorno externo?
M4	Texto + Estructura	¿La estructura mejora al texto?
M5	Texto + Contexto	¿El contexto mejora al texto?

M6	Texto + Estructura + Contexto	¿Combinar toda la información mejora el resultado?
-----------	-------------------------------	--

Tabla 1. Especificaciones predictivas evaluadas en el estudio. Fuente: elaboración propia.

4.2.1. Modelo supervisado

Las especificaciones fueron evaluadas mediante pipelines de scikit-learn que integran el preprocesamiento y el estimador, reduciendo el riesgo de fuga de información entre las fases de entrenamiento y validación. Tras la comparación realizada exclusivamente sobre TRAIN, se seleccionó **M4 (Texto + Estructura)** como especificación oficial.

Para la clasificación se empleó **LinearSVC**, apropiado para representaciones textuales TF-IDF de alta dimensionalidad y matrices dispersas. La selección final se realizó antes de consultar TEST, preservando así la independencia de la evaluación final.


4.3. Validación, robustez e interpretabilidad

Dado el desbalance de la variable objetivo, la evaluación priorizó **Balanced Accuracy y Macro-F1**, complementadas con Precision, Recall y F1 de la clase No positiva. La *accuracy* convencional se mantuvo únicamente como métrica complementaria.

Además de la evaluación final sobre TEST, se realizaron análisis de sensibilidad y robustez para comprobar la estabilidad de las conclusiones ante diferentes condiciones de los datos. Estos análisis incluyeron escenarios de cobertura contextual, periodo temporal, agrupación por POI, ampliación del conjunto de entrenamiento y evaluación territorial externa.

Finalmente, la interpretabilidad del modelo se abordó mediante el análisis de los coeficientes de **LinearSVC**, identificando términos y variables asociados con cada clase, junto con una revisión de errores de clasificación. Estas asociaciones se interpretan como **señales predictivas y no como relaciones causales**.

Los resultados de estas evaluaciones se presentan en el capítulo 6, evitando utilizar TEST para modificar retrospectivamente la especificación seleccionada.



5. RECURSOS Y HERRAMIENTAS TECNOLÓGICAS

El desarrollo de PARCHAR se realizó principalmente en **Python sobre Google Colab**, utilizando herramientas orientadas al procesamiento de datos, Procesamiento del Lenguaje Natural, Machine Learning y visualización. La selección tecnológica priorizó la **reproducibilidad, trazabilidad e integración** de las diferentes etapas del proyecto.

Componente	Tecnología / recurso	Aplicación en PARCHAR
Programación y entorno	Python · Google Colab	Desarrollo y ejecución reproducible del pipeline
Procesamiento de datos	pandas · NumPy	Limpieza, transformación e integración.
PLN y Machine Learning	TF-IDF, scikit-learn, LinearSVC	Representación textual, entrenamiento y evaluación.
Control de Calidad	Pipelines – validaciones QA	Trazabilidad y prevención de fugas de información.
Visualización	Matplotlib · Tableau	Análisis exploratorio y Business Intelligence

Gestión de archivos	Google Drive	Organización de datos, modelos y resultados.
Reproducibilidad	random_state = 42, TRAIN/TEST, CV estratificada	Consistencia del diseño experimental

Tabla 2. Tecnologías y recursos utilizados en PARCHAR Intelligence.

Las fuentes externas utilizadas proceden de organismos y repositorios públicos, entre ellos DANE, Banco de la República, Registro Nacional de Turismo (RNT) y ANATO. Su procedencia, utilización y referencias se documentan en la bibliografía y en los anexos correspondientes.

El código, los resultados detallados y los controles de calidad del proceso analítico se conservan en el notebook del proyecto, mientras que la memoria principal presenta únicamente los elementos necesarios para interpretar el desarrollo y sus resultados.

6. RESULTADOS Y DISCUSIÓN

6.1. Caracterización del conjunto de datos

El dataset analítico final quedó compuesto por **861 reseñas correspondientes a 25 puntos de interés (POI)** de los cinco clústeres turísticos estudiados. La variable objetivo presentó un desbalance relevante: **733 reseñas positivas (85,13 %) y 128 no positivas (14,87 %)**.

Esta distribución confirma que la *accuracy* convencional no resulta suficiente para evaluar el problema: un modelo podría alcanzar un valor elevado favoreciendo sistemáticamente la clase mayoritaria. Por esta razón, la comparación de modelos priorizó **Balanced Accuracy, Macro-F1 y el desempeño específico sobre la clase No positiva**.

6.2. Comparación y selección de modelos

La validación cruzada realizada exclusivamente sobre TRAIN mostró que **el texto constituye la principal fuente de capacidad predictiva**. El baseline M0 evidenció la insuficiencia de una estrategia basada únicamente en la clase mayoritaria, mientras que M1 (Texto) produjo una mejora sustancial.

La incorporación de información estructural en **M4 (Texto + Estructura)** proporcionó el mejor desempeño durante el proceso de selección y, por tanto, esta especificación fue fijada como modelo oficial antes de consultar TEST. En contraste, la incorporación del bloque contextual en M5 y M6 no produjo una mejora consistente.

Este resultado constituye un hallazgo relevante: **incorporar un mayor número de variables no implica necesariamente obtener un modelo mejor**. En el dominio estudiado, la señal contenida en el lenguaje de las reseñas resultó más informativa que buena parte de los indicadores externos considerados.




Figura 2. Comparación del rendimiento de las especificaciones M0–M6 mediante Balanced Accuracy en validación cruzada sobre TRAIN. Fuente: elaboración propia.

6.3. Evaluación final sobre el conjunto TEST

Una vez seleccionada M4, se realizó una única evaluación sobre las **173 observaciones del conjunto TEST**, que habían permanecido aisladas durante el desarrollo.

En el conjunto TEST independiente, M4 alcanzó una Balanced Accuracy del 80,53 %, un Recall del 69,23 % y un F1 del 64,29 % para la clase No positiva. En términos operativos, el modelo identificó correctamente 18 de las 26 experiencias No positivas, lo que equivale a detectar aproximadamente 7 de cada 10 casos de insatisfacción.

Balanced Accuracy	Recall No positiva	F1 No positiva
80,53 %	69,23 %	64,29 %

	Predicción: NO POSITIVA	Predicción: POSITIVA
Real: NO POSITIVA	18 	8 
Real: POSITIVA	12 	135 

Figura 3. Matriz de confusión del modelo oficial M4 sobre el conjunto TEST independiente ($n = 173$). Fuente: elaboración propia.

6.4. Comparación Benchmark M1 vs. M4

En TEST, el modelo basado exclusivamente en texto **M1** obtuvo una Balanced Accuracy de **0,8314**, ligeramente superior al **0,8053 de M4**.

Sin embargo, M4 se mantuvo como modelo oficial porque había sido seleccionado previamente mediante validación cruzada sobre TRAIN. Sustituirlo retrospectivamente por M1 después de

observar TEST habría utilizado el conjunto de evaluación como criterio de selección, comprometiendo su independencia metodológica.

Modelo	Balanced Accuracy TEST	Interpretación
M1 - Texto	0,8314	Mejor resultado descriptivo en TEST
M4 – Texto + Estructura	0,8053	Modelo oficial seleccionado en TRAIN

Tabla 3. Comparación de M1 y M4 sobre TEST.

El resultado refuerza la importancia del texto como principal fuente predictiva y, al mismo tiempo, evidencia que el valor incremental de las variables estructurales es moderado y dependiente de la muestra.

6.5. Robustez y capacidad de generalización

Los experimentos posteriores mostraron que el rendimiento aumenta al ampliar el volumen de datos disponible dentro del mismo dominio. Al incrementar TRAIN de **688 a 1.466 observaciones (+113,08 %)**, ambos modelos mejoraron su capacidad predictiva.

Modelo	TEST original	TRAIN ampliado
M1	0,8314	0,8823
M4	0,8053	0,8664

Tabla 4. Efecto de la ampliación del conjunto de entrenamiento.

Este comportamiento proporciona evidencia favorable sobre el valor de incrementar la cobertura de reseñas dentro de dominios conocidos. Sin embargo, debe interpretarse como **evidencia de escalabilidad experimental y no como garantía de rendimiento futuro**.

6.6. Interpretabilidad y análisis de errores

El análisis de los coeficientes del modelo permitió identificar términos y características asociados con cada clase. Las reseñas clasificadas como Positivas presentan patrones lingüísticos diferenciados de aquellas asociadas con experiencias No positivas, confirmando que el modelo no se limita a reproducir la distribución mayoritaria, sino que utiliza información contenida en el lenguaje.




Figura 4. Principales términos asociados a experiencias Positivas y No positivas según los coeficientes del modelo M4. Fuente: elaboración propia.

6.7. Discusión e implicaciones para Business Intelligence

Hipótesis	Evidencia principal	Conclusión
H1 – El texto contiene señal predictiva	M1 supera ampliamente al baseline y mantiene alto desempeño en TEST	Respaldada
H2 – Estructura y contexto aportan valor incremental	M4 mejora la selección en CV; el contexto no aporta mejoras consistentes	Parcialmente respaldada
H3 – Robustez y generalización	El rendimiento mejora con más datos intra-dominio, pero disminuye en territorio no observado	Respaldada con limitaciones

Tabla 5. Evaluación de las hipótesis de investigación

Los resultados respaldan la utilidad de las reseñas como fuente de inteligencia turística y muestran que el componente textual concentra gran parte de la señal predictiva. La incorporación de información adicional debe evaluarse empíricamente: las variables estructurales aportaron valor durante la selección, mientras que el bloque contextual no generó mejoras sistemáticas.

Los experimentos de robustez muestran además que el crecimiento del corpus puede mejorar el rendimiento dentro del dominio conocido, pero la transferencia a nuevos territorios requiere cautela. En consecuencia, el valor de PARCHAR no reside en asumir un modelo universal, sino en disponer de una **arquitectura analítica reproducible que pueda ampliarse y validarse progresivamente**.

7. PARCHAR INTELLIGENCE: APLICACIÓN Y BUSINESS INTELLIGENCE

PARCHAR Intelligence traslada los resultados del proceso analítico a una perspectiva orientada a negocio. Su propósito no es únicamente clasificar reseñas como Positivas o No positivas, sino transformar la voz digital del viajero en señales que faciliten la comprensión de la experiencia turística y apoyen la toma de decisiones de prestadores y gestores.

La solución se plantea como una arquitectura de inteligencia turística en la que las reseñas constituyen la principal fuente de señal predictiva y se complementan con información estructural del destino y del punto de interés. Sobre esta base, los resultados del modelo se integran en una capa de Business Intelligence que permite consultar indicadores, identificar patrones de satisfacción e insatisfacción y analizar diferencias entre destinos, POI y periodos.

7.1. De la predicción a la decisión

Desde una perspectiva empresarial, el valor de PARCHAR puede sintetizarse en tres niveles:

Señal analítica	Lectura de negocio	Aplicación potencial
Clasificación Positiva / No positiva	Identificación de señales de satisfacción e insatisfacción	Priorización de experiencias que requieren revisión
Patrones lingüísticos asociados a cada clase	Reconocimiento de aspectos recurrentes en la experiencia del visitante	Identificación de fortalezas y posibles puntos de fricción
Indicadores agregados por destino, POI y periodo	Seguimiento de patrones de la experiencia turística	Apoyo a decisiones operativas y de gestión

De esta manera, el modelo predictivo funciona como una **capa analítica intermedia**: recibe información no estructurada procedente de las reseñas, la transforma mediante el pipeline desarrollado y genera señales que posteriormente se exploran mediante la capa de Business Intelligence desarrollada.

7.2. Capa de Business Intelligence

Como extensión aplicada del proyecto, se desarrolló **PARCHAR Intelligence en Tableau**, una capa interactiva de Business Intelligence orientada a facilitar la interpretación de los resultados por perfiles no técnicos. El tablero integra la información analítica en una interfaz visual que permite explorar la experiencia turística mediante filtros y comparaciones por destino, punto de interés, periodo y otras dimensiones disponibles.

La solución se organiza en tres vistas complementarias. La primera ofrece una lectura ejecutiva de los principales indicadores de la experiencia turística; la segunda profundiza en el comportamiento de las reseñas y permite explorar patrones entre destinos y puntos de interés; y la tercera incorpora una perspectiva contextual, relacionando la evolución de las reseñas con indicadores externos como la **TRM, la tasa de desempleo, la ocupación hotelera y las agencias de viajes**.

Esta última perspectiva permite ampliar la lectura de la experiencia turística más allá del contenido textual de las reseñas y observarla dentro del entorno económico y sectorial en el que se produce. Los indicadores contextuales se presentan mediante su evolución temporal y medidas resumen, facilitando la identificación de patrones y periodos de interés sin establecer relaciones causales que los datos no permiten demostrar.

El tablero funciona como un mecanismo de consulta y apoyo a la decisión, y no como sustituto del criterio del gestor. Su utilidad reside en reducir la distancia entre el resultado técnico del análisis y su interpretación empresarial, facilitando que prestadores y gestores turísticos puedan descubrir patrones, profundizar en ellos y utilizarlos como señales para orientar decisiones.

7.3. Prueba de concepto y productivización

Como prueba de concepto de productivización, se desarrolló un reseñador que permite ingresar nuevas opiniones y aplicar sobre ellas la lógica de inferencia del pipeline entrenado, obteniendo

una clasificación predictiva. Este componente aproxima el modelo a un escenario de uso y demuestra que PARCHAR no se limita al análisis retrospectivo de las 861 reseñas utilizadas durante el TFM.

No obstante, cualquier evolución hacia una aplicación empresarial requeriría mecanismos adicionales de incorporación de datos, monitorización del rendimiento, reentrenamiento y validación ante nuevos destinos. Los experimentos realizados muestran que la capacidad de generalización puede variar fuera del dominio observado, por lo que las predicciones deben utilizarse como **señales de apoyo a la decisión y no como decisiones automatizadas**.

En conjunto, PARCHAR Intelligence conecta **datos, analítica predictiva y Business Intelligence** dentro de un mismo flujo de valor: las reseñas permiten escuchar al viajero; el modelo transforma esa información en señales analíticas; y la capa de visualización facilita su interpretación para **descubrir, analizar y decidir**.

8. CONCLUSIONES Y LÍNEAS FUTURAS

El desarrollo de PARCHAR demuestra que las reseñas turísticas constituyen una fuente de información con capacidad predictiva para analizar la experiencia de los viajeros. Los experimentos realizados evidencian que **el componente textual concentra la mayor parte de la señal predictiva**, mientras que las variables estructurales aportan valor incremental en determinadas configuraciones y las variables contextuales no producen mejoras consistentes en las condiciones evaluadas.

El diseño experimental permitió seleccionar **M4 (Texto + Estructura)** mediante validación cruzada exclusivamente sobre TRAIN y evaluar posteriormente su comportamiento sobre un conjunto TEST independiente. Los análisis complementarios mostraron además que el aumento de datos dentro del dominio mejora el rendimiento, mientras que la aplicación sobre territorios no observados presenta una mayor dificultad. Por tanto, la expansión del modelo debe acompañarse de **nuevos datos, reentrenamiento y validación específica**, evitando asumir una generalización automática.

Desde una perspectiva aplicada, el principal aporte del proyecto no reside únicamente en la clasificación de reseñas, sino en la construcción de una arquitectura reproducible que conecta **Data Engineering, Procesamiento del Lenguaje Natural, Machine Learning y Business Intelligence**. Sobre esta base, **PARCHAR Intelligence** plantea una forma de transformar la voz digital del viajero en información interpretable para prestadores, gestores y otros actores del sector turístico.

La prueba de concepto desarrollada permite además aplicar el modelo sobre nuevas reseñas, constituyendo un primer paso hacia su productivización. Los resultados deben entenderse como una **herramienta de apoyo a la decisión y no como sustituto del conocimiento experto**, especialmente ante nuevos destinos o contextos distintos de los utilizados durante el entrenamiento.

8.1 Líneas futuras

La evolución de PARCHAR puede orientarse principalmente a:

- **Ampliar la cobertura territorial y el volumen de reseñas**, incorporando nuevos destinos y POI mediante procesos periódicos de validación y reentrenamiento.
- **Extender el análisis lingüístico**, evaluando representaciones semánticas avanzadas y capacidades multilingües para reseñas en otros idiomas.
- **Profundizar la inteligencia turística**, integrando nuevas fuentes únicamente cuando demuestren valor analítico o utilidad para negocio.
- **Avanzar hacia la productivización**, mediante servicios de inferencia, monitorización del rendimiento e integración de los resultados con herramientas de Business Intelligence.

En conjunto, PARCHAR Intelligence conecta captura de información, analítica predictiva y Business Intelligence dentro de un mismo flujo de valor: el reseñador permite incorporar la voz del viajero; el modelo transforma esa información en señales analíticas; y la capa de visualización facilita su interpretación para descubrir, analizar y decidir.

9. BIBLIOGRAFÍA

- Asociación Colombiana de Agencias de Viajes y Turismo (ANATO). (2025). *Compendio de cifras del sector turístico* [Tablero interactivo]. Tableau Public <https://public.tableau.com/app/profile/anato4868/viz/CompendioANATO/Compendio>
- Banco de la República de Colombia. (2026). *Tasa de cambio del peso colombiano (TRM) frente al dólar estadounidense* [Serie estadística]. Portal de Estadísticas Económicas. Datos utilizados hasta el 31 de julio de 2026. Recuperado el 8 de agosto de 2026 de https://suameca.banrep.gov.co/estadisticas-economicas/informacionSerie/1/tasa_cambio_peso_colombiano_trm_dolar_usd.
- Centro de Pensamiento Turístico de Colombia (CPTUR). (2025). *Índice de Competitividad Turística Regional de Colombia (ICTRC): Ciudades capitales y municipios con vocación turística 2025*. Fundación Universitaria Cafam (UNICAFAM) y Asociación Hotelera y Turística de Colombia (COTELCO).
- Departamento Administrativo Nacional de Estadística (DANE). (2025). *Gran Encuesta Integrada de Hogares (GEIH) 2024* [Microdatos]. Dirección de Metodología y Producción Estadística (DIMPE), Archivo Nacional de Datos (ANDA). Recuperado el 6 de junio de 2026 de (<https://microdatos.dane.gov.co/index.php/catalog/819>).
- Departamento Administrativo Nacional de Estadística (DANE). (2026). *Encuesta Mensual de Alojamiento (EMA): diciembre de 2025. Anexo estadístico* [Archivo Excel]. DANE. Anexo estadístico EMA – diciembre de 2025 (<https://www.dane.gov.co/files/operaciones/EMA/anex-EMA-dic2025.xlsx>).
- Géron, A. (2023). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (3rd edition). O'Reilly Media.
- Jurafsky, D., & Martin, J. H. (2026). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition* (3rd edition, online manuscript) <https://web.stanford.edu/~jurafsky/slp3/>.
- Ministerio de Comercio, Industria y Turismo (MinCIT). (2026). *Registro Nacional de Turismo (RNT)* [Conjunto de datos]. Datos Abiertos Colombia. Datos consultados con corte al 6 de junio de 2026. Recuperado el 6 de junio de 2026 de https://www.datos.gov.co/Comercio-Industria-y-Turismo/Registro-Nacional-de-Turismo-RNT/thwd-ivmp/about_data.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., VanderPlas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830 <https://www.jmlr.org/papers/v12/pedregosa11a.html>.

10. ANEXOS

Como soporte documental y técnico del presente Trabajo Fin de Máster se adjunta un conjunto de anexos que permiten consultar la trazabilidad de las fuentes utilizadas, reproducir el desarrollo analítico y explorar los componentes complementarios de PARCHAR Intelligence.

- **Anexo I. Confirmación de ANATO sobre el uso académico de la información**
Comunicación por correo electrónico de Mile Lorena Piñeros Dueñas, Analista de Estudios Económicos de ANATO, septiembre de 2026.
- **Anexo II. Índice de Competitividad Turística Regional de Colombia (ICTRC) 2025**
Documento del Centro de Pensamiento Turístico de Colombia (CPTUR), elaborado por la Fundación Universitaria Cafam (UNICAFAM) y la Asociación Hotelera y Turística de Colombia (COTELCO), utilizado como fuente contextual del proyecto.
- **Anexo III. Notebook reproducible de PARCHAR Intelligence**
Notebook desarrollado en Google Colab que contiene el pipeline completo de adquisición, preparación, integración, Procesamiento del Lenguaje Natural, modelado, validación, análisis de robustez, interpretabilidad y controles de calidad del proyecto, incluyendo la prueba de concepto *Tourist Review Analyzer* para la inferencia sobre nuevas reseñas.
- **Anexo IV. Business Intelligence — PARCHAR Intelligence**
Tablero interactivo desarrollado en Tableau como capa de visualización y apoyo a la interpretación de los resultados analíticos.

Repositorio del proyecto y materiales reproducibles:

- <https://github.com/ljohamoren/PARCHAR-Intelligence-TFM>

Relación de archivos anexos:

- **ANEXO I:** Leidy_Johanna_Moreno_Posada_Confirmacion_ANATO.pdf
- **ANEXO II:** Leidy_Johanna_Moreno_Posada_ICTRC_2025.pdf
- **ANEXO III — HTML:** Leidy_Johanna_Moreno_Posada_PARCHAR_Notebook.html
- **ANEXO IV — TABLEAU:** Leidy_Johanna_Moreno_Posada_PARCHAR_Tableau.twbx
Tableau Public:
<https://public.tableau.com/app/profile/leidy.johanna.moreno.posada/viz/TABLEAUPARCHARINTELLIGENCJMP/Dashboard1?publish=yes>

Material audiovisual de entrega:

- **VIDEO:** Leidy_Johanna_Moreno_Posada_PARCHAR_Video.mp4